AI Ethics (5DA06) – cheat sheet (VI)

*thuật ngữ **in đậm** = tiếng Anh như trong đề; (tác giả, năm) = trích dẫn để ghi vào bài*

0 Đề thi & cách viết bài

- Thi viết trên giấy 2h, **có tài liệu kèm đề** (document & discussion study). Đề mẫu: 6 câu dài + 4 câu ngắn.
- Câu ngắn kiểu "kể tên 2–3 **methods** phân tích sociotechnical system" = 2/20 điểm: chỉ cần *tên*.
- Giảng viên nói chắc chắn có **1 câu về framing**; mỗi bài giảng có thể có 1 câu.
- **Bẫy Schufa**: có người duyệt lại ≠ tự động là *không* "fully automated" (mục 8).
- Họ chấm *cách lập luận và đánh đổi* (trade-offs), không chỉ đáp án.

Khung trả lời câu dài (5 khối)

- 1) **Reframe**: ai hỏi, mục tiêu gì, phạm vi (gạch chân từ khóa đề, vd. "scientific", "independent").
- 2) **Actors & stakes**: ai liên quan, ai được/mất, quan hệ quyền lực.
- 3) **Concepts** của bài giảng + trích dẫn (Tubaro 2020, Gornet 2024…).
- 4) **Recommendations** cụ thể, đo được (ai làm, làm gì, kiểm tra thế nào).
- 5) **Limits / trade-offs**: framing của chính mình loại trừ cái gì; lựa chọn chuẩn tắc (normative choice) nói rõ.

1 AI là sociotechnical system (Viard)

- **AI** = khái niệm chung chỉ các hệ thống *học suy luận từ dữ liệu*; thuật ngữ **polysemic** (đa nghĩa): kỹ thuật, báo chí, luật, khoa học định nghĩa khác nhau.
- Ví dụ thành công/thất bại "ồn ào" và "im lặng": AlphaGo, spam filters, COMPAS, SyRI. Thách thức: tách **hype** khỏi thực tế.
- **Sociotechnical system**: nghiên cứu *vật thể kỹ thuật và con người như một hệ thống*; actors định hình không gian xã hội họ ở trong đó. Không gian của AI bị định hình bởi (3) 1) bối cảnh chính trị & luật 2) thực tế kỹ thuật 3) trí tưởng tượng chung (imaginaries).
- **STS** (Science and Technology Studies): vật thể kỹ thuật trong xã hội; sự **reception** (tiếp nhận) không thể bỏ qua: cách dùng xuất hiện, thay đổi, biến mất.
- Sự chú ý của công dân và nhà hoạch định là **tài nguyên hữu hạn**; quyết định được đưa ra trong **sub-political spaces** *(Beck, 1986)*.
- Quá trình **variation & selection** dẫn tới **stabilisation**, với **interpretive flexibility** rồi **closure** (đóng lại một nghĩa).
- AI Act: "essential to clarify the *role of actors*" ⇒ xác định actors và vai trò.

Framing (chắc chắn có trong đề)

- **Framing** = chọn *vật thể bắt đầu và kết thúc ở đâu*: AI chỉ là code Python? + mô hình toán + dữ liệu + người thu thập/gán nhãn + GPU, mỏ + người dùng + luật…
- Framing quyết định *cái gì được đo, cái gì vô hình*. Ví dụ **life cycle analysis** (ACV): bắt đầu đếm phát thải từ đâu? Hai con số với framing khác nhau *không so sánh được*.
- Mở rộng framing: đầy đủ hơn nhưng khó đo; thu hẹp: đo được nhưng bỏ sót. Luôn *nói rõ và biện minh* framing của mình.

Methods phân tích sociotechnical system (7)

- 1) framing 2) **ethnography** & phỏng vấn tại chỗ 3) **discourse analysis** 4) **computational methods** 5) tạo **sociotechnical imaginaries** (utopia/dystopia) 6) tập trung vào **controversies** & điểm căng thẳng 7) so sánh các nguồn khác nhau: báo chí, khoa học, luật, xã hội dân sự.

Actors & roles trong hệ thống AI (Q1 đề mẫu)

- **Researchers** (định nghĩa, phương pháp); **providers / Big Tech** (xây và bán mô hình); **deployers** (cơ quan, công ty dùng); **data workers** (trainer, verifier, imitator); **users / data subjects** (bị tác động, chống cự, khiếu nại); **regulators** (EU, CNIL, AI Office); **standardisation bodies** (CEN-CENELEC); **media**; **civil society** / NGOs (ProPublica, La Quadrature); **investors**; **miners / hardware** (Crawford).
- Mỗi actor: *đóng góp gì + lợi ích + quyền lực*.

2 Lịch sử xã hội của AI

- Thuật ngữ AI có từ **1950s**, nhưng AI hôm nay khác hẳn. **Định kiến**: phát triển tuyến tính (symbolic trước, neural nay); chu kỳ **hype** (Gartner) hiếm khi đúng thực tế.
- **Symbolic AI** / expert systems / decision trees: học bán thủ công từ dữ liệu + tri thức chuyên gia. **Neural AI**: suy luận thống kê, bỏ chuyên gia, cần nhiều dữ liệu. **Generative AI**: tự tạo ví dụ huấn luyện?
- *(Cardon, Cointet & Mazières 2018,* La revanche des neurones*)*: AI là thay đổi paradigm của tính toán; **bi-clustering** mạng trích dẫn (Louvain) cho thấy căng thẳng **symbolic vs connectionist**.
- **Connectionist tenets** (4): 1) hy sinh tính dễ hiểu & chặt chẽ để nắm độ phức tạp của dữ liệu 2) dữ liệu đủ dư thừa/đối xứng để bền vững 3) thế giới thực lộn xộn, phi tuyến 4) dữ liệu phải được chia nhỏ (atomised, granularised).
- *(Gargiulo et al. 2023)*: Microsoft Academic Graph, **139 triệu** bài báo ⇒ (5) 1) nhiều ngành con phụ thuộc nhau 2) symbolic, neural, neuro-symbolic cùng phát triển 3) chia giữa lý thuyết và ứng dụng 4) chịu ảnh hưởng báo chí & tiểu thuyết 5) đang bước vào vùng bị quản lý. ⇒ phải coi AI là sociotechnical object.

3 Materiality: môi trường & quyền lực

- **Rematerialising the cloud** *(Crawford 2021,* Atlas of AI*)*: phụ thuộc mỏ (lithium); 99.8% đất đào là chất thải; 1 tấn đất hiếm = 75 000 L nước axit + 1 tấn chất phóng xạ; điều kiện lao động tồi tệ.
- Deep learning tốn **carbon** và **lao động** *(Luccioni et al. 2023, BLOOM)*; không phải lúc nào cũng tốt hơn *(Delarue et al. 2024)*.
- Xu hướng: **frugal AI**, ước lượng carbon, "green AI", **no AI**. **Moral reconfiguration** của nghiên cứu *(Hardy 2023)*.
- **Data colonialism**: trích xuất giá trị từ dữ liệu, mở rộng của chủ nghĩa thực dân & tư bản *(Zuboff)*: lợi nhuận + tập trung của cải; tăng bất bình đẳng Bắc–Nam. Ví dụ **ngôn ngữ**: cộng đồng cho dữ liệu ngôn ngữ, rồi bị bán lại dưới dạng dịch vụ.
- **Reactivity** *(Espeland & Sauder 2007)*: số đo công khai *tái tạo* thế giới xã hội (trường học chạy theo tiêu chí xếp hạng). "Ta có tìm thấy cái ta đo?"
- *(Kalluri 2020)*: đừng hỏi AI có tốt/công bằng không, hãy hỏi nó **dịch chuyển quyền lực** thế nào.
- **Decolonial AI** *(Mohamed et al. 2020)*: hành động cá nhân *không đủ* (vấn đề hệ thống), nền tảng thay thế cũng không đủ (Mastodon vs X). Thách thức ý tưởng "dữ liệu là tài nguyên tự nhiên"; media literacy, regulation, đa nguyên thật sự.

4 Digital labour & data work (Abel)

- **Platform**: công ty trung gian ghép nối người, thông tin, hàng hóa và **thu dữ liệu** từ tương tác; **taskification** (chia việc thành tác vụ nhỏ); không phải Taylorism cổ điển: điều phối *ngoài* công ty. **Triangulation** platform–worker–client *(Abel & Dieuaide 2023)*.
- **Digital labour = continuum** từ hoạt động không lương của user (điền hồ sơ, đánh giá) tới việc vặt trả theo món và freelance *(Terranova, free labor)*; thiếu quyền lao động (nghỉ phép, hưu trí, thậm chí được trả lương).
- Vì sao quan trọng: AI **dịch chuyển** chứ không **thay thế** lao động ⇒ bùng nổ micro-workers. Lời hứa "việc người tạm thời trước khi tự động hóa" *phần lớn sai*.
- **Clients** (Big Tech, start-ups, R&D, labs) cần: chất lượng nhãn > số lượng; phủ lĩnh vực & đặc thù địa phương; dữ liệu cập nhật; đánh đổi chính xác–chi phí–thời gian; bí mật & nguồn gốc; giảm rủi ro.
- *(Muldoon et al. 2024)*: **AI data work** = lao động người để chuẩn bị/đánh giá dữ liệu và đầu ra, thường thuê ngoài, trả thấp. Typology **(2 trục)**: crowdworker vs employee; dịch vụ ngoài vs trong, tổng quát vs chuyên AI.
- *(Schmidt 2022)*: để đạt 95–99% độ chính xác, trung gian thành **multi-layer stacks**; "black boxes within black boxes" (lớp ẩn tổ chức giống lớp ẩn mạng) ⇒ chính xác hơn nhưng **mờ đục** về nguồn gốc & điều kiện lao động.

3 vai trò *(Tubaro, Casilli & Coville 2020)*

- 1) **Trainer / preparation** (trước robot): **data generation** (ghi giọng, ảnh, giọng địa phương) + **annotation** (phân loại, bounding box, polygon, phân đoạn pixel).
- 2) **Imitator / impersonation**: người *đóng vai* AI, "**artificial artificial intelligence**" (MTurk). Google Duplex (tới 25% cuộc gọi do người, 5/2019), Julie Desk (80% máy/20% người).
- 3) **Verifier / verification** (sau robot): hệ thống đã chạy, người kiểm tra & sửa (nghe clip ASR 3–15 s, chấm độ liên quan, sửa OCR) ⇒ *không bao giờ biến mất*.

Phân công lao động toàn cầu

- Platforms/BPO = định chế **offshoring** mới. Cầu ở Bắc Mỹ/Âu; cung ở Nam Á, Đông Âu, Mỹ Latin, châu Phi. World Bank 2023: **154–435 triệu** người làm việc online (4.4–12.5% lao động).
- MTurk: US ≈75%, India ≈16%; 100–200k đăng ký, ≈2k hoạt động; half-life 12–18 tháng.
- Lao động trẻ, học vấn cao hơn mặt bằng, kinh tế khó khăn. Lương: median ≈**$1.77/h**, mean $3.13/h *(Hara et al. 2018)*; thời gian không lương (tìm việc, bị từ chối).
- **Dispositif** *(Miceli & Posada 2022)*: instructions + interface + metrics quyết định "sự thật" và nhịp độ. Nội dung bạo lực/tình dục. Phụ nữ 1/3–40%, chênh lệch thu nhập (vd. 68%).
- **Venezuela** *(Posada 2022)*: USD như phao cứu sinh giữa siêu lạm phát; $0.7–2/h; mất điện, phí rút tiền; việc rẻ nhất (captcha, selfie).
- **Madagascar** *(Le Ludec 2024)*: BPO nói tiếng Pháp làm cho khách Pháp; *journaliers* (trả theo ngày, không nghỉ phép); QA nhiều tầng; impersonation (phát hiện trộm từ video trực tiếp: "they said it was all automatic…we're the ones behind it").

Q2 đề mẫu – value chain của annotation: 1) client Pháp (vd. start-up camera chống trộm siêu thị) cần dữ liệu 2) giao cho platform / BPO trung gian (hợp đồng, SLA độ chính xác) 3) BPO ở Madagascar chia việc (taskification): gán nhãn video, impersonation trực tiếp 4) worker (journalier, lương thấp, bị theo dõi bởi metrics) 5) QA nhiều tầng → dữ liệu về client → mô hình được bán là "tự động". Giá trị & uy tín ở Bắc, chi phí & vô hình ở Nam.

5 Bức tranh AI ethics (Q3 đề mẫu)

- **AI ethics**: nghiên cứu liên ngành (CS, kinh tế, luật, toán, xã hội học). Mục tiêu (4): 1) tách hype/thực tế 2) hiểu cách diễn ngôn, lập luận, actors liên kết 3) chỉ ra vùng cần luật 4) hướng dẫn vận hành.
- *(Jobin, Ienca & Vayena 2019)*: **84** văn bản, **11 chủ đề**: transparency, justice & fairness, non-maleficence, responsibility, privacy, beneficence, freedom & autonomy, trust, sustainability, dignity, solidarity. Hội tụ quanh **5** (5 cái đầu); bất đồng về *cách hiểu và triển khai*.
- *(Gornet, Delarue, Boritchev & Viard, FAccT 2024)*: **436** manifestos (MapAIE) ⇒ **3 cực**: technical, regulatory, business/innovation. XAI: kỹ thuật hơn, ít luật; fairness: không đổi; AGI: ít kỹ thuật, ít luật; freedom/autonomy: nhiều luật & công bằng xã hội. Theo thời gian: AI ethics **chuyển thành AI regulation**; vẫn **thiếu operationalisation** (trừ theo lĩnh vực) và thiếu visibilisation.
- Chủ đề **bị thiếu**: AI & lao động, AI & đấu tranh quyền lực (bất công, sexism), AI & sinh thái.
- Liên tục: **charters** → **regulation** → **standards**.
- Báo chí (1000 bài tiếng Pháp, n-gram, χ^2, Louvain): cụm technical, private sector, transhumanist, regulation, bioethics; 2023–25: RIA (AI Act), OpenAI, IA générative, chính trị Mỹ.
- **Hype**: AI là thuật ngữ rộng, không phải 1 công nghệ; có ứng dụng có ích, hype = khoảng cách giữa tuyên bố và thực tế (Hinton 2016 về radiologists). Làm với industry không bị coi là xung đột lợi ích; hội nghị chú trọng hiệu năng.

4 arenas / nuances of regulation *(Benbouzid et al. 2020)*

- 1) **AI as super-intelligence**: transhumanist, sợ mất kiểm soát (Wiener, Good, Moravec, Russell), Future of Life Institute. Phê phán: rủi ro dài hạn giả định *làm xao nhãng* tác hại thực, ngắn hạn *(Bender et al. 2021)*.
- 2) **Intelligent agents in an open world**: Asilomar 2009 (AAAI), chuyên gia nhận diện rủi ro, AI là thành phần kỹ thuật *có thể chứng nhận*; One Hundred Year Study, Partnership on AI.
- 3) **Tech neutrality vs sociotechnical**: AI củng cố cấu trúc quyền lực *(Weizenbaum 1976)*; bias có hệ thống *(Buolamwini & Gebru 2018)*; audits, báo cáo; căng thẳng giữa giải pháp kỹ thuật và vấn đề chính trị sâu.
- 4) **Technical & economic lens** (EU): tạo **conformity** cho sản phẩm; GDPR, DSA, DMA, AI Act; **Brussels effect** *(Bradford)*; định nghĩa rộng + phụ lục dễ sửa.

AI ethics vs AI safety

- **AI safety**: rủi ro tồn vong; Musk, Altman, Hinton, Bengio, Bostrom, Kurzweil; trung tâm Bắc Mỹ; được chú ý (Bletchley, AI Safety Institute, code of practice). Lập luận: AI như hạt nhân ⇒ luật *lấy công nghệ làm trung tâm*, bỏ qua phi kỹ thuật; **TESCREAL** *(Gebru & Torres 2024)*.
- Lời kêu gọi "tạm dừng 6 tháng": không ai dừng; không có bằng chứng công khai.

6 Users of AI: bias & technosolutionism

- Vì sao quan tâm user (5): 1) ta cũng là user 2) giữ niềm tin vào thể chế 3) thấy trở ngại, non-use, phân biệt 4) gắn **metrological realism** 5) giúp operationalisation (luật).
- **COMPAS** (ProPublica 2016): đánh giá nguy cơ tái phạm; case bias kinh điển; tranh cãi chuyển từ luật/tội phạm học ra không gian công cộng; 2 arenas (data science vs criminology) ít trao đổi *(Beaudouin & Maxwell 2023)*.
- Bias hôm nay: nhiều phương pháp debias (Bolukbasi 2016) kết quả lẫn lộn, có khi *tăng* bias *(Prost 2021)*; định nghĩa fairness cũ, không vững về xã hội học, hiếm khi **intersectionality**. ⇒ tranh luận về **algocracy**.
- **Fair AI vs radical AI**: SyRI (Hà Lan, gian lận phúc lợi), Schufa (ADM & human oversight), CNAF (Pháp, Conseil d'État 2024), ETIAS (biên giới), Clearview AI (nhận diện

khuôn mặt, phạt 2025) ⇒ fairness vô nghĩa nếu không gắn với *thay đổi sâu (Kalluri 2020; Keyes 2020)*; **compounding injustice** *(Eidelson 2021)*; cần **compassion** *(Vaccaro 2021)*.

- **Mulching proposal** *(Keyes, Hutson & Durbin 2019)*: áp FAT (fair, accountable, transparent) vào thuật toán biến người già thành thức ăn: *fair* (demographic parity), *accountable* (10 giây khiếu nại), *transparent* (biển "mulching area") ⇒ FAT không hỏi *có nên làm không*.
- **Technosolutionism**: tin công nghệ *tất yếu* là một phần của giải pháp ⇒ hợp lý hóa sau, giải pháp xa rời thực tế; nguy cơ cho dân chủ *(Nemitz 2023)*; abstraction traps *(Selbst et al. 2018)*. Ví dụ Covid tracing: tranh luận về privacy thay vì Bluetooth không phù hợp.
- Lập luận lobby (4): "không làm thì người khác làm"; "chảy máu chất xám"; "luật cản đổi mới"; "phiên bản mới sẽ sửa lỗi cũ".

Algorithms in practice *(Christin 2017/2019)*

- Ethnography 2011–15, 100 phỏng vấn: luật sư/thẩm phán (defendant scoring) vs nhà báo web (trend mining). Hai **expert fields** *(Bourdieu)*; khác: rào cản gia nhập (mạnh vs gần như không), phi lợi nhuận vs lợi nhuận.
- Chung: **decoupling** *(Meyer & Rowan 1977)* (diễn ngôn quản lý ≠ thực hành); **buffering** (3): 1) **foot-dragging** (lờ đi công cụ) 2) **gaming** (clickbait, chọn hồ sơ) 3) **open critique**.
- **Algorithmic imaginaries** *(Bucher 2016)*: nhà báo không nghi công cụ mà nghi *mục đích*; thẩm phán chê thuật toán "crude", công cụ vì lợi nhuận.
- **Cour de cassation**: NER để ẩn danh bản án, huấn luyện nội bộ 2 năm, *không bao giờ xong* (đội thường trực); gọi là "the software", như một đồng nghiệp vắng mặt.

7 Explanation & contestation

- **Right to explanation** (EU): giải thích nên **selective, mutable, dialogic** *(Miller)*; **contrastive** *(Dessalles 2020)*. Cho ai: chuyên gia, người thường, cơ quan quản lý. Để làm gì: descriptive, explanatory, normative, **contestable**.
- **Right to contest AI** *(Kaminski & Urban 2021)*: quyền cá nhân, mô phỏng **due process**; đặt gánh nặng lên cá nhân; vừa với GDPR. Mục tiêu: trao quyền công dân, chấp nhận quyết định, cải thiện hệ thống, chống gaming. Giới hạn: không giải quyết **bất cân xứng thông tin** và quyền lực; mỗi người chỉ đấu cho hồ sơ của mình.
- **Contestable AI by design** *(Alfrink et al. 2023)*: **Value-Sensitive Design**, vòng khiếu nại cho **public AI**.

8 Human in the loop & bẫy Schufa

Schufa (CJEU, C-634/21): công ty chấm điểm tín dụng; điểm số được bên thứ ba dùng gần như nguyên xi. Tòa: nếu người "duyệt" *luôn đồng ý* với hệ thống thì *không có* giám sát thật ⇒ coi là **fully automated decision** (GDPR art. 22) ⇒ kích hoạt quyền: giải thích, can thiệp của người, khiếu nại. **Câu hỏi bẫy**: "có người thì không phải tự động hoàn toàn?" → **Sai**, nếu sự can thiệp không **meaningful**.

- **Human in the loop** (người trong từng quyết định) vs **human supervision / oversight** (người đứng trên hệ thống). Meaningful review cần: thẩm quyền đảo ngược, thời gian, thông tin, đào tạo, tránh **automation bias**.
- Khi đề hỏi về human in the loop: *ai* là người đó, thuê thế nào, trả bao nhiêu, nội bộ hay thuê ngoài (lời giảng viên Abel).

9 Luật: soft law, đạo đức, GDPR, trách nhiệm (Le Goff)

- **Soft law**: thỏa thuận/nguyên tắc *không ràng buộc*; **hard law**: nghĩa vụ ràng buộc, thực thi trước tòa. Điều kiện (3) (Conseil d'État 2013): 1) nhằm thay đổi hành vi qua tự nguyện 2) tự nó không tạo quyền/nghĩa vụ 3) mức hình thức hóa giống quy tắc luật.
- Nhược điểm: không ràng buộc; thiếu an toàn pháp lý, bỏ qua thể chế dân chủ; cách né luật cứng. Soft law **có thể có hiệu lực**: công ty tuyên bố tuân theo (FTC, CNIL thực thi) hoặc thể chế trao hiệu lực (standard trong luật, thẩm phán dùng để xác định lỗi).
- Nguyên tắc: **HLEG 2019** (7): human agency & oversight; technical robustness & safety; privacy & data governance; transparency; diversity, non-discrimination & fairness; societal & environmental well-being; accountability. **OECD** 2019/2024 (5). **UNESCO** 2021 (10).

GDPR

- **Một legal basis** (art. 6, "OR") (6): consent, contract, legal obligation, vital interest, **public interest**, legitimate interest.
- **Mọi principles** (art. 5, "AND") (6): 1) lawfulness, fairness, transparency 2) purpose limitation 3) data minimisation & accuracy 4) storage limitation 5) integrity & confidentiality 6) **accountability** (chứng minh được tuân thủ).
- Pseudonymisation (vẫn là dữ liệu cá nhân) ≠ anonymisation.

Rủi ro pháp lý của LLM (3)

- 1) **Data protection** (legal basis, principles, không xuất dữ liệu cá nhân) 2) **Intellectual property** (làm sạch dataset, tôn trọng **opt-out**, lọc đầu ra, điều khoản sử dụng) 3) **Liability**: hợp đồng (vụ **Air Canada** chatbot), dân sự (**faute + préjudice + lien de causalité**), hình sự; sản phẩm lỗi (**produit + défaut de sécurité**); trách nhiệm do vật (chose + gardien).
- **Copyright**: bảo vệ "*original expression, by a human, in a fixed medium*"; ý tưởng/thuật toán không, mã nguồn có; không cần thủ tục. **Fair use** (US) (4 yếu tố): 1) mục đích (transformative?) 2) bản chất tác phẩm 3) lượng trích 4) ảnh hưởng thị trường. EU: ngoại lệ **text and data mining** (nghiên cứu; thương mại có opt-out).

10 EU AI Act

- Lịch sử: HLEG 2018 → guidelines 2019 → white paper 2020 → đề xuất 2021 → thông qua 13/6/2024 → **hiệu lực 1/8/2024**, áp dụng dần: cấm 2/2025; GPAI 8/2025; phần lớn 8/2026; high-risk Annex I 8/2027 (theo văn bản gốc).
- **AI system** = hệ thống dựa trên máy, *tự chủ ở các mức*, (có thể thích nghi sau triển khai), vì mục tiêu rõ/ngầm, **infers** từ input cách tạo output (dự đoán, nội dung, khuyến nghị, quyết định) ảnh hưởng môi trường. Đặc trưng chính: **khả năng suy luận** (ML *và* logic/knowledge-based); loại trừ luật do người viết sẵn (recital 12).
- Actors (4): **provider** (đưa ra thị trường dưới tên mình: tuân thủ *ex ante*, CE marking); **deployer** (dùng dưới thẩm quyền, trừ cá nhân: theo hướng dẫn sử dụng; thành provider nếu đổi tên/sửa cơ bản); **distributor**; **importer**.

Kim tự tháp rủi ro (4 + GPAI)

- 1) **Prohibited** (art. 5) (8): subliminal techniques; khai thác điểm yếu (tuổi, khuyết tật, hoàn cảnh); **social scoring**; dự đoán khả năng phạm tội của cá nhân (chỉ từ profiling); **untargeted scraping** để làm CSDL khuôn mặt; **emotion recognition** ở nơi làm việc/trường học; **biometric categorisation** suy ra dữ liệu nhạy cảm; **real-time remote biometric identification** nơi công cộng cho thực thi pháp luật (ngoại lệ: bắt cóc, buôn người, người mất tích, khủng bố, nghi phạm tội nặng; cần cho phép trước).
- 2) **High-risk**: sản phẩm theo luật ngành (Annex I: máy, thiết bị y tế, hàng không, xe…) hoặc **Annex III** (8): biometrics; critical infrastructure; education; employment; essential services (y tế, tín dụng, bảo hiểm); law enforcement; migration & border; justice & democratic processes.
- Nghĩa vụ provider high-risk: art. 9 risk management; 10 **data governance** (bias, đại diện, dữ liệu sạch); 11 tài liệu kỹ thuật (Annex IV); 12 logs; 13 transparency & hướng dẫn cho deployer; 14 **human oversight** (giao diện, nút "stop", quyền ghi đè); 15 accuracy, robustness, cybersecurity; 17 quality management.
- 3) **Transparency** (art. 50): chatbot báo đang nói với AI; nội dung tổng hợp **watermark**; emotion/biometric báo cho người liên quan; **deepfake** phải công bố (trừ nghệ thuật/châm biếm); văn bản thông tin cho công chúng.
- 4) Minimal risk: tự nguyện theo code/nguyên tắc.
- **GPAI model**: tổng quát đáng kể, làm nhiều tác vụ. Nghĩa vụ (4): tài liệu kỹ thuật; thông tin cho downstream; chính sách **copyright** (opt-out); **tóm tắt dữ liệu huấn luyện** công khai (open-source miễn 2 cái đầu). **Systemic risk**: $> 10^{25}$ FLOPs hoặc Commission chỉ định ⇒ thêm (4): đánh giá & adversarial testing; đánh giá & giảm rủi ro hệ thống; báo cáo sự cố nghiêm trọng cho AI Office; cybersecurity.
- Thực thi: **AI Office** (GPAI), **AI Board**, cơ quan quốc gia; **regulatory sandboxes**. Phạt: cấm 35 tr€/7%; high-risk & transparency 15 tr€/3%; không hợp tác 7.5 tr€/1% (lấy mức cao hơn).
- **Standards**: tuân thủ = thử theo **harmonised standards** (hENs) ⇒ CE mark; mới: chứng nhận **fundamental rights**, khó vì phụ thuộc ngữ cảnh, cần phán quyết tòa; tính dân chủ của tổ chức tiêu chuẩn bị đặt câu hỏi *(Gornet & Maxwell 2024)*.
- Công cụ đánh giá rủi ro: NIST AI RMF 2023, ANSSI 2024, ALTAI 2020. Ma trận: **gravity** (0–4) × **probability** (0–4) + mitigation.

11 Đề mẫu – dàn ý trả lời

Q1: 5 vai trò actors & đóng góp

- Researchers (định nghĩa, framing AI), providers (xây, bán), deployers (dùng, chịu nghĩa vụ), data workers (trainer/verifier/imitator: chất lượng dữ liệu), regulators/standard bodies (luật, CE), users/data subjects (dùng, chống cự, khiếu nại), media/NGOs (đưa tranh cãi ra công chúng: ProPublica). Mỗi vai trò: 1 câu đóng góp + 1 ví dụ.

Q3: báo cáo cho chính phủ Pháp về các xu hướng AI ethics

- Chủ đề cần xem: 1) nguyên tắc (Jobin 11 chủ đề; HLEG 7) 2) ba cực diễn ngôn (Gornet 2024) & chuyển thành luật 3) AI ethics vs AI safety (framing rủi ro khác nhau, TESCREAL) 4) 4 arenas (Benbouzid) 5) bias & fair vs radical AI (COMPAS, SyRI, CNAF) 6) lao động (Tubaro, Le Ludec: Madagascar gắn với Pháp!) 7) môi trường (Crawford, frugal AI) 8) users, explanation, contestation 9) standards & AI Act.
- Với mỗi chủ đề: *vì sao liên quan* + *ai mang nó* (actor, arena) + *vị trí* (technical / regulatory / business). Nêu chủ đề bị thiếu (lao động, quyền lực, sinh thái).

Q4: videosurveillance thuật toán (Bộ Nội vụ) – vấn đề pháp lý

- **GDPR** (và chỉ thị **Police-Justice** 2016/680 nếu mục đích thực thi pháp luật): legal basis = public interest / nhiệm vụ công; **necessity & proportionality**; minimisation (không lưu khuôn mặt, làm mờ); storage limitation (xóa sau thời hạn ngắn); transparency (biển báo *dễ thấy*, thông tin công khai); dữ liệu sinh trắc là **sensitive** (art. 9); **DPIA** bắt buộc (giám sát có hệ thống nơi công cộng quy mô lớn); hỏi **CNIL**.
- Quyền cơ bản: riêng tư, tự do đi lại & hội họp (**chilling effect**), không phân biệt (bias theo nhóm), nguy cơ **function creep** (mở rộng mục đích).
- **AI Act**: Bộ Nội vụ là **deployer** (cơ quan công). Phân loại: nếu *nhận dạng người bằng sinh trắc thời gian thực* ⇒ **bị cấm** (trừ ngoại lệ hẹp + cho phép trước của tòa/cơ quan độc lập). Nếu chỉ phát hiện *sự kiện* (đám đông, vật bỏ quên, xâm nhập) không nhận dạng ⇒ không phải RBI; xét **Annex III** (biometrics, law enforcement) ⇒ có thể **high-risk**. Pháp: thử nghiệm VSA thuật toán cho Thế vận hội (loi n° 2023-380, art. 10), không nhận diện khuôn mặt; được kéo dài dù kết quả ít.
- **Biện pháp cụ thể** cho deployer high-risk: mua hệ thống có **CE marking** & tài liệu; dùng đúng hướng dẫn; **human oversight** bởi nhân viên được đào tạo, có quyền bỏ qua cảnh báo (tránh bẫy Schufa: không duyệt máy móc); giữ **logs**; theo dõi & báo sự cố cho provider/cơ quan; **fundamental rights impact assessment** (cơ quan công); đăng ký vào CSDL EU; thông báo cho người dân; kiểm tra bias theo nhóm; giới hạn thời gian/khu vực sự kiện; đánh giá sau sự kiện & công bố kết quả.
- Mở rộng (điểm cao): framing (ai đo "rủi ro"?), technosolutionism (camera có giải quyết vấn đề an ninh?), lao động ẩn (ai gán nhãn video huấn luyện?), contestation (người bị gắn cờ khiếu nại thế nào?).

Đề mẫu khác: panel khoa học độc lập cho AI Act

- "Scientific" = gắn với nghiên cứu; "independent" = độc lập với Commission. Cân bằng theo **Gargiulo 2023** (tỉ lệ lĩnh vực: lý thuyết vs ứng dụng; symbolic vs connectionist) + chuyên gia AI & society (ethics *và* safety vì framing rủi ro khác nhau, xã hội học, nhân học, design cho explanation/contestation, luật). Cân bằng giới, địa lý (Bắc–Nam), academia/industry (xung đột lợi ích).
- Tài liệu kỹ thuật của OpenAI "FAT": cẩn thận **mulching proposal** (fair ≠ nên làm); metrics fairness nào, cho ai (intersectionality); explanation cho ai (Miller), có cho phép **contestation**?; lao động dữ liệu & môi trường bị bỏ ngoài framing; kiểm toán độc lập, không chỉ tự khai.