AI Ethics (5DA06) – Short note

*Ghi chú ngắn bằng tiếng Việt; thuật ngữ **in đậm** giữ nguyên tiếng Anh như trong slide và đề thi.*

Câu chuyện của cả môn trong 5 dòng. (1) "AI" không chỉ là thuật toán: nó là một **sociotechnical system** gồm người, dữ liệu, máy, luật và diễn ngôn. (2) Cách ta **frame** (đóng khung) AI quyết định ta thấy gì và bỏ sót gì. (3) Đằng sau AI có **materiality**: mỏ khoáng, điện, và hàng triệu **data workers** vô hình. (4) Khi được dùng thật, AI bị người dùng chống cự, lách, khiếu nại; "fair AI" chưa đủ nếu không hỏi về **power**. (5) Châu Âu trả lời bằng luật: từ **soft law** (charters) sang **hard law** (GDPR, **AI Act**) và **standards**.

1. AI là một sociotechnical system

Ý chính: Đừng nhìn AI như "một đoạn code". Hãy nhìn cả hệ thống: ai thiết kế, ai gán nhãn dữ liệu, ai dùng, ai bị ảnh hưởng, ai làm luật, báo chí nói gì.

- Từ "AI" **đa nghĩa** (polysemic): nhà khoa học, nhà báo, nhà làm luật, doanh nghiệp đều dùng nhưng hiểu khác nhau. Định nghĩa AI là một cuộc *tranh giành* (fight for scientific space).
- **STS** (Science and Technology Studies) nghiên cứu công nghệ trong xã hội: sự *tiếp nhận* quan trọng, cách dùng xuất hiện rồi biến mất.
- Sự chú ý của công chúng có hạn; nhiều quyết định quan trọng được đưa ra trong **sub-political spaces** *(Beck 1986)*, tức ngoài nghị trường (phòng lab, ủy ban tiêu chuẩn, công ty).
- Một công nghệ lúc đầu có **interpretive flexibility** (nhiều cách hiểu), rồi qua tranh cãi đi tới **closure / stabilisation** (một nghĩa thắng).
- Có thể chia không gian tranh luận thành các **arenas**: nhóm người có cùng niềm tin (tenets).

Framing – khái niệm quan trọng nhất

- Framing = quyết định *vật thể nghiên cứu bắt đầu và kết thúc ở đâu*. AI chỉ là code? Hay code + mô hình + dữ liệu + người gán nhãn + GPU + mỏ lithium + người dùng + luật?
- Ví dụ **life cycle analysis**: tính phát thải carbon của mô hình từ lúc nào – từ huấn luyện, hay từ khai mỏ để làm GPU? Hai con số với framing khác nhau không so sánh được.
- Framing rộng: đầy đủ hơn nhưng khó đo. Framing hẹp: dễ đo nhưng làm vô hình một số tác hại. Không có framing "trung lập".

Trong bài thi: luôn nói rõ framing của bạn và vì sao chọn nó. Giảng viên nói chắc chắn có một câu về framing.

Phương pháp phân tích (câu hỏi ngắn dễ lấy điểm)

Framing; ethnography & phỏng vấn; discourse analysis; computational methods (mạng, clustering); xây sociotechnical imaginaries; theo dõi controversies; so sánh báo chí / khoa học / luật / xã hội dân sự.

2. AI đến từ đâu?

- AI có từ thập niên 1950, nhưng *không* phát triển tuyến tính "symbolic rồi neural".
- **Symbolic AI** dựa trên luật và chuyên gia; **connectionist / neural AI** học thống kê từ dữ liệu lớn, bỏ qua chuyên gia.
- *(Cardon, Cointet & Mazières 2018,* La revanche des neurones*)*: phân cụm mạng trích dẫn cho thấy hai cộng đồng đối đầu. Niềm tin của connectionists: chấp nhận mất tính dễ hiểu để nắm độ phức tạp; dữ liệu đủ dư thừa; thế giới thực lộn xộn; dữ liệu phải chia nhỏ.
- *(Gargiulo et al. 2023)*: 139 triệu bài báo ⇒ AI là nhiều ngành con phụ thuộc nhau, symbolic và neural cùng tồn tại, chia lý thuyết/ứng dụng, chịu ảnh hưởng báo chí và bắt đầu bị quản lý.
- **Hype**: khoảng cách giữa lời hứa và thực tế (Hinton 2016: "trong 5 năm deep learning thắng bác sĩ X-quang").

3. Materiality: AI có "thân xác"

Ý chính: "Cloud" không phi vật chất: AI cần khoáng sản, nước, điện và lao động người.

- *(Crawford 2021,* Atlas of AI*)*: khai mỏ (lithium, đất hiếm), ô nhiễm, điều kiện lao động tệ.
- Deep learning tốn carbon *(Luccioni 2023, BLOOM)* và không phải lúc nào cũng tốt hơn phương pháp đơn giản. Xu hướng: frugal AI, green AI, "no AI".
- **Data colonialism**: lấy dữ liệu của người dùng (thường ở Nam bán cầu) để tạo lợi nhuận tập trung ở Bắc; ví dụ dữ liệu ngôn ngữ của cộng đồng bị bán lại cho chính họ.
- **Reactivity** *(Espeland & Sauder 2007)*: khi một con số được công bố, người ta thay đổi hành vi để làm đẹp con số (trường đại học chạy theo bảng xếp hạng).
- *(Kalluri 2020)*: câu hỏi đúng không phải "AI có fair không" mà "AI **dịch chuyển quyền lực** thế nào".

4. Người lao động phía sau AI

Ý chính: AI không thay thế lao động mà *dịch chuyển* nó: tới các micro-workers ở nước nghèo, được trả theo tác vụ, vô hình với người dùng.

- **Platform** ghép nối khách hàng và người làm, chia việc thành tác vụ nhỏ (**taskification**) và thu dữ liệu.
- **Digital labour** là một **continuum**: từ việc không lương của user (đánh giá, gắn thẻ) tới micro-task trả vài xu.
- **3 vai trò** *(Tubaro, Casilli & Coville 2020)*:
  1. **Trainer** (preparation): tạo và gán nhãn dữ liệu *trước* khi có mô hình.
  2. **Imitator** (impersonation): người *giả làm* AI ("artificial artificial intelligence"): Google Duplex, Julie Desk, nhân viên Madagascar xem camera chống trộm.
  3. **Verifier** (verification): người kiểm tra và sửa đầu ra *sau* khi hệ thống chạy; việc này không bao giờ hết.
- Chuỗi nhiều tầng *(Schmidt 2022)*: "black boxes within black boxes", khách hàng không biết ai thật sự làm việc.
- Điều kiện: lương median ≈ $1.77/giờ *(Hara 2018)*; thời gian không lương; giám sát bằng metrics *(Miceli & Posada 2022)*; nội dung độc hại; chênh lệch giới.
- Case: **Venezuela** (sống còn nhờ USD giữa siêu lạm phát) *(Posada 2022)*; **Madagascar** (BPO nói tiếng Pháp, lương theo ngày) *(Le Ludec 2024)*.

Trong bài thi: khi bài nói "human in the loop", hãy hỏi: người đó là ai, được thuê thế nào, trả bao nhiêu, nội bộ hay thuê ngoài?

5. AI ethics nói gì về chính nó

- *(Jobin et al. 2019)*: 84 bộ nguyên tắc, 11 chủ đề; đồng thuận quanh 5 chủ đề (transparency, justice & fairness, non-maleficence, responsibility, privacy) nhưng hiểu và áp dụng khác nhau.
- *(Gornet et al. 2024)*: 436 manifestos chia thành 3 cực: **technical**, **regulatory**, **business/innovation**. Theo thời gian, ethics biến thành **regulation**; vẫn thiếu **operationalisation** (biến nguyên tắc thành việc làm cụ thể).
- Chủ đề hay bị thiếu: lao động, quyền lực, môi trường.
- **4 arenas** *(Benbouzid et al. 2020)*: (1) super-intelligence (sợ AI vượt kiểm soát); (2) open-world agents (chuyên gia chứng nhận kỹ thuật, Asilomar); (3) sociotechnical critique (AI củng cố quyền lực, bias); (4) technical–economic (EU tạo chuẩn tuân thủ, Brussels effect).
- **AI safety** (rủi ro tồn vong, chủ yếu Mỹ, lãnh đạo tech) vs **AI ethics** (tác hại hiện tại). Phê phán: lo rủi ro giả định làm quên tác hại thật *(Bender 2021)*; **TESCREAL** *(Gebru & Torres 2024)*.

6. Người dùng AI

- **COMPAS** (ProPublica 2016): thuật toán dự đoán tái phạm bị cáo buộc thiên vị chủng tộc; trở thành biểu tượng của AI bias.
- Debiasing kỹ thuật có kết quả lẫn lộn; định nghĩa fairness hiếm khi tính tới **intersectionality**.
- **Fair AI vs radical AI**: các vụ SyRI, CNAF, Schufa, Clearview cho thấy vấn đề là *có nên dùng*, không chỉ *dùng sao cho công bằng*.
- **Mulching proposal** *(Keyes et al. 2019)*: bài châm biếm làm một hệ thống khủng khiếp trở nên "fair, accountable, transparent" ⇒ FAT không thay thế được câu hỏi đạo đức.
- **Technosolutionism**: tin rằng mọi vấn đề cần giải pháp công nghệ. Lập luận lobby quen thuộc: "người khác sẽ làm", "chảy máu chất xám", "luật giết đổi mới", "bản sau sẽ sửa".
- *(Christin)*: luật sư và nhà báo **chống cự** thuật toán: **foot-dragging** (lờ đi), **gaming** (lách chỉ số), **open critique**. Diễn ngôn quản lý tách khỏi thực hành (**decoupling**).
- **Right to explanation**: giải thích phải chọn lọc, đối thoại, so sánh (contrastive), phù hợp người nghe. **Right to contest** *(Kaminski & Urban 2021)*: như due process; nhưng đặt gánh nặng lên cá nhân và không xóa bất cân xứng quyền lực. **Contestable by design** *(Alfrink 2023)*.

Trong bài thi: bẫy **Schufa**: có người duyệt chưa chắc đã "không tự động". Nếu người đó gần như luôn theo máy, Tòa CJEU coi là **fully automated decision** (GDPR art. 22) và người bị ảnh hưởng có quyền giải thích, khiếu nại.

7. Luật: từ soft law tới AI Act

- **Soft law** (charters, nguyên tắc): không bắt buộc, có thể dùng để *né* luật cứng; nhưng có thể có hiệu lực khi công ty cam kết công khai hoặc thẩm phán/cơ quan dùng nó.
- Nguyên tắc chính thức: HLEG 2019 (7 yêu cầu trustworthy AI), OECD, UNESCO.
- **GDPR**: mỗi xử lý cần *một* legal basis (consent, contract, legal obligation, vital interest, public interest, legitimate interest) *và* tuân thủ *mọi* principles (lawfulness/fairness/transparency, purpose limitation, minimisation & accuracy, storage limitation, integrity & confidentiality, accountability).
- LLM có 3 rủi ro pháp lý: dữ liệu cá nhân, bản quyền (opt-out, TDM), trách nhiệm (hợp đồng như Air Canada, dân sự: lỗi + thiệt hại + quan hệ nhân quả, hình sự).

AI Act – đọc theo 3 câu hỏi

1. **Có phải AI system?** Hệ thống máy, có mức tự chủ, **suy luận** (infer) từ input để tạo output. Luật thuần do người viết thì không.
2. **Mình là ai? Provider** (làm ra, chịu tuân thủ trước khi bán, CE) hay **deployer** (dùng, theo hướng dẫn, giám sát) hay distributor/importer.
3. **Rủi ro mức nào? Prohibited** (social scoring, nhận dạng sinh trắc thời gian thực nơi công cộng cho cảnh sát trừ ngoại lệ, emotion recognition ở trường/công sở…) → **high-risk** (Annex III: biometrics, giáo dục, việc làm, tín dụng, cảnh sát, biên giới, tư pháp…: risk management, data governance, logs, human oversight, robustness) → **transparency** (chatbot, deepfake, watermark) → minimal. Riêng **GPAI**: tài liệu, copyright, tóm tắt dữ liệu; $> 10^{25}$ FLOPs ⇒ systemic risk.

- Thực thi: AI Office, AI Board, cơ quan quốc gia; phạt tới 35 tr€ / 7% doanh thu.
- **Standards** (hENs) biến luật thành bài kiểm tra kỹ thuật; khó với quyền cơ bản vì chúng phụ thuộc ngữ cảnh *(Gornet & Maxwell 2024)*.

Trong bài thi: đề luật kiểu "videosurveillance": (1) xác định vai trò (deployer công) (2) phân loại rủi ro (nhận dạng người ⇒ có thể bị cấm; chỉ phát hiện sự kiện ⇒ xét high-risk) (3) GDPR: legal basis, proportionality, DPIA, CNIL, biển báo (4) biến mỗi nghĩa vụ thành *biện pháp cụ thể*: ai làm, làm gì, kiểm tra thế nào.

8. Cách đạt điểm cao

- Đọc kỹ tài liệu kèm đề và *dùng* nó (vd. bài Gargiulo trong đề mẫu về panel).
- Mỗi ý: khái niệm + tác giả + ví dụ cụ thể + hệ quả.
- Nêu *trade-offs* và lựa chọn chuẩn tắc của bạn; giảng viên chấm cách lập luận.
- Kết nối các bài: framing ↔ lao động vô hình ↔ human oversight ↔ AI Act.